



AI 能力测评报告（极小规模验证）

本报告为小样本快速验证，旨在跑通测评流程并初步了解各模型表现，不具备统计显著性。

测评信息

项目	内容
测评日期	2026-05-27
测评人	开发团队
测评版本	v1.0.0
测试数据库	MySQL 8.0 (ECS)
样本规模	极小（每用例 1 批次 × 10 条，无重复）
参与模型	deepseek-v4-pro, mimo-v2.5-pro
temperature	0.8
batchSize	10

1. 场景 A：字段值生成测评

1.1 测试用例选取

从完整矩阵中选取 6 个代表性用例：

用例ID	字段	类型	核心检验点
A-01	t_user.username	VARCHAR(32)	长度、非空、多样性

用例ID	字段	类型	核心检验点
A-02	t_user.email	VARCHAR(128)	格式合法性
A-03	t_user.age	TINYINT UNSIGNED	数值范围
A-08	t_product.sku	VARCHAR(12)	短字符串边界
A-10	t_order.amount	DECIMAL(10,2)	精度与正数
A-14	描述="中国大陆手机号"	VARCHAR(20)	语义理解

1.2 详细测试结果

deepseek-v4-pro

用例ID	合规数/总数	约束合规率	语义评分(/25)	多样性	格式OK	延迟(ms)
A-01	10/10	100%	24	100%	Y	2130
A-02	10/10	100%	24	100%	Y	1980
A-03	10/10	100%	23	90%	Y	1860
A-08	9/10	90%	21	100%	Y	2240
A-10	10/10	100%	23	90%	Y	1920
A-14	10/10	100%	23	90%	Y	2050

备注:

- A-08: 1 条生成了 "SKU-20260527A" (13 位) , 超出 VARCHAR(12) 限制
- A-03: 年龄分布合理 (18-72) , 有 2 条重复值 28

mimo-v2.5-pro

用例ID	合规数/总数	约束合规率	语义评分(/25)	多样性	格式OK	延迟(ms)
A-01	10/10	100%	22	90%	Y	1450
A-02	9/10	90%	21	80%	Y	1380

用例ID	合规数/总数	约束合规率	语义评分(/25)	多样性	格式OK	延迟(ms)
A-03	10/10	100%	20	80%	Y	1290
A-08	8/10	80%	19	90%	Y	1520
A-10	10/10	100%	22	80%	Y	1350
A-14	9/10	90%	21	80%	Y	1410

备注:

- A-02: 1 条生成了 "zhangsan@email", 缺少顶级域名后缀
- A-08: 2 条超出 12 字符限制, 分别为 14 位和 15 位
- A-14: 1 条生成了 "13800000000" 明显测试号码, 语义不够真实
- 整体延迟显著低于 deepseek-v4-pro (平均快约 35%)

1.3 场景 A 评分汇总

deepseek-v4-pro

维度	原始值	得分(/满分)	权重	加权得分
约束合规率	98.3% (59/60)	38/40	40%	15.2
语义相关度	均分 23.0	23.0/25	25%	5.8
多样性	95.0%	18/20	20%	3.6
格式正确率	100% (6/6)	15/15	15%	2.3
合计				26.9 → 百分制 89.5

mimo-v2.5-pro

维度	原始值	得分(/满分)	权重	加权得分
约束合规率	93.3% (56/60)	34/40	40%	13.6
语义相关度	均分 20.8	20.8/25	25%	5.2

维度	原始值	得分(/满分)	权重	加权得分
多样性	83.3%	15/20	20%	3.0
格式正确率	100% (6/6)	15/15	15%	2.3
合计				24.1 → 百分制 80.3

2. 场景 B：规则建议测评

2.1 测试用例

选取 `t_user` (8 字段, 含 1 个 AUTO_INCREMENT) 作为测试表。

2.2 详细结果

deepseek-v4-pro 推荐结果

字段	推荐ruleType	类型合理	ruleConfig 示例
id	(跳过)	-	AUTO_INCREMENT 字段已跳过
username	LLM_DESCRIPTION	Y	<code>{"description":"中国人姓名, 覆盖常见姓氏"}</code>
email	REGEX	Y	<code>{"pattern":"[a-z]{4,8}[0-9]{0,3}@gmail"</code>
age	RANGE	Y	<code>{"min":18,"max":70,"type":"int"}</code>
balance	RANGE	Y	<code>{"min":0,"max":100000,"type":"decimal"}</code>
status	ENUM	Y	<code>{"values":["ACTIVE","INACTIVE","BANNED"],"weight"</code>
created_at	RANGE	Y	<code>{"min":"2024-01-01","max":"2026-05-27","type":"d"</code>
bio	LLM_DESCRIPTION	Y	<code>{"description":"用户个人简介, 50-200字, 涵盖职业、"</code>

- 类型准确率: $7/7 = 100\%$
- 平均参数评分: **4.7/5**

- 覆盖率: 7/7 = **100%** (正确跳过 AUTO_INCREMENT)
- 延迟: 3420ms

mimo-v2.5-pro 推荐结果

字段	推荐ruleType	类型合理	ruleConfig 示例
id	(跳过)	-	AUTO_INCREMENT 字段已跳过
username	REGEX	N	<code>{"pattern":"[a-zA-Z][a-zA-Z0-9_]{3,15}"}</code>
email	REGEX	Y	<code>{"pattern":"[a-z]+[0-9]*@[a-z]+\\.com"}</code>
age	RANGE	Y	<code>{"min":1,"max":120,"type":"int"}</code>
balance	RANGE	Y	<code>{"min":0.00,"max":999999.99,"type":"decimal"}</code>
status	ENUM	Y	<code>{"values":["ACTIVE","INACTIVE","BANNED"]}</code>
created_at	RANGE	Y	<code>{"min":"2020-01-01","max":"2026-12-31","type":"t"}</code>
bio	LLM_DESCRIPTION	Y	<code>{"description":"个人简介"}</code>

- 类型准确率: 6/7 = **85.7%**
- 平均参数评分: **3.0/5**
- 覆盖率: 7/7 = **100%**
- 延迟: 2180ms

问题分析:

- username 推荐 REGEX 而非 LLM_DESCRIPTION, 不适合中文姓名场景
- email 的 pattern 过于宽泛, 可匹配无效格式如 "a@b.com"
- status 缺少 weights 配置
- bio 的 description 过于简短, 缺乏具体约束

2.3 场景 B 评分汇总

模型	类型准确率(40%)	参数合理性(35%)	覆盖率(25%)	场景B得分
deepseek-v4-pro	100% → 40	4.7/5 → 94% → 32.9	100% → 25	97.9

模型	类型准确率(40%)	参数合理性(35%)	覆盖率(25%)	场景B得分
mimo-v2.5-pro	85.7% → 34.3	3.0/5 → 60% → 21.0	100% → 25	80.3

3. 多模型对比


3.1 综合对比表

模型	场景A得分	场景B得分	总分(A×0.7+B×0.3)	平均延迟	等级
deepseek-v4-pro	89.5	97.9	92.0	2030ms	S
mimo-v2.5-pro	80.3	80.3	80.3	1400ms	A

3.2 雷达图数据（可视化参考）

	约束合规	语义相关	多样性	格式正确	延迟(反向)	规则建议
deepseek-v4-pro:	98	92	95	100	65	98
mimo-v2.5-pro:	93	83	83	100	100	80

3.3 性能-质量象限



3.4 各维度胜出对比

对比维度	胜出模型	差距
约束合规率	deepseek-v4-pro	+5.0% (98.3% vs 93.3%)
语义相关度	deepseek-v4-pro	+2.2 (23.0 vs 20.8)
多样性	deepseek-v4-pro	+11.7% (95.0% vs 83.3%)
响应速度	mimo-v2.5-pro	快 31% (1400ms vs 2030ms)
规则建议质量	deepseek-v4-pro	+17.6 (97.9 vs 80.3)
格式正确率	持平	均为 100%

4. 回退机制测评

场景ID	注入方式	触发回退	回退后数据质量	日志正确	备注
F-01	配置无效 API Key	Y	合格	Y	3 次重试后正常回退 DefaultGenerator
F-02	Mock 返回 []	Y	合格	Y	立即回退，无多余等待
F-03	Mock 返回 "这是一段文字"	Y	合格	Y	parseValuesFromResponse 捕获异常
F-04	设置 1ms 超时	Y	合格	Y	观察到 1s→2s→4s 间隔重试
F-05	Mock 每次只返回 3 条	Y(部分)	合格	Y	循环补充直到满足 totalRows

回退机制评估：通过 - 所有异常场景均能正确触发回退，数据生成不中断。

5. 测评结论

模型排名

排名	模型	总分	等级	特点
1	deepseek-v4-pro	92.0	S	约束理解强，规则建议专业，综合质量高
2	mimo-v2.5-pro	80.3	A	速度优势明显（快 31%），基础能力合格

最佳模型推荐

场景	推荐模型	理由
综合最优	deepseek-v4-pro	约束合规率 98.3%，规则建议接近满分
延迟敏感	mimo-v2.5-pro	平均延迟 ~1.4s，适合交互式实时预览
规则建议	deepseek-v4-pro	参数配置质量 4.7/5 远超 mimo 的 3.0/5
多模型混合	两者随机混合	兼顾速度与质量，当前项目已支持此模式

发现的问题

- 短 VARCHAR 边界遵守**：两个模型在 VARCHAR(12) 场景均出现超长值，deepseek-v4-pro 超长率 10%，mimo-v2.5-pro 超长率 20%。Prompt 中已有长度约束但执行不够严格。
- mimo 规则建议粒度不足**：mimo-v2.5-pro 对 username 字段推荐 REGEX 而非 LLM_DESCRIPTION，未能识别"中文姓名"语义；description 内容普遍简短。
- mimo 多样性偏低**：email 和 age 字段的生成值出现明显聚集（80% 多样性），可能与 temperature 设置有关。

优化建议

- Prompt 强化**：对 VARCHAR(n) 且 $n < 36$ 的短字段，在 prompt 末尾追加 "重要：每个值必须 $\leq n$ 个字符，生成前请逐一验证长度"
- 模型分工策略**：
 - 规则建议（场景 B）固定使用 deepseek-v4-pro（质量差距大）

- 数据生成（场景 A）可混合使用两模型（质量差距可接受）
3. **mimo 参数调优**：尝试将 mimo 的 temperature 提升至 0.9-1.0 以改善多样性
 4. **考虑开启 Extended Thinking**：mimo 支持 `thinking: true`，deepseek 支持 `thinking.type: enabled`，建议在规则建议场景测试思维链对质量的提升效果
-

6. 局限性声明

- 本报告样本量极小（每模型 6 用例 × 1 批次 × 10 条 = 60 条），结果仅供参考
- 未进行多轮重复测试，无法计算置信区间和标准差
- 单次测试可能受网络波动、模型负载等外部因素影响
- 测评日模型版本可能后续更新，结论存在时效性
- 建议后续扩大至完整测评（每用例 5 批次 × 3 轮）后形成正式结论