



智能测试数据生成工具 · 演示文档

目录

- 一、现状与痛点
- 二、方案设计与亮点
- 三、成果展示
- 四、流程演示

一、现状与痛点

1.1 现状

测试数据构造是软件测试流程中不可或缺的基础环节，直接影响测试的覆盖度与有效性。当前，测试团队在造数时普遍依赖以下方式：手工编写 INSERT 语句、编写脚本批量生成、调用 mock 工具产出随机数据、利用历史数据复制或脱敏、借助 AI 大模型直接生成等。这些方式各有局限，难以独立应对日益复杂的业务场景——尤其是涉及多表关联、码值对齐、复合约束的大数据构造需求。

1.2 痛点

1. 大规模数据构造存在天花板

当数据构造涉及的 SQL 逻辑过于复杂或关联表过多时，无论是人工编写还是 AI 直接生成，都容易因信息量过大超出处理能力上限，导致构造失败或数据质量不可控；复杂关联关系下，AI 对表间依赖的解析易出现误判，最终产出的数据无法通过业务校验。

2. 多种造数方式相互孤立，无法融合

手工造数擅长精确控制但效率极低，mock 工具产出快但真实感差，AI 生成语义丰富但约束合规率不稳定——每种方式各有适用场景，但测试人员的实际需求往往是混合型的：既需要多表关联一致性，又需要单字段语义真实感，还需要特定码值精确匹配，单一方式无法覆盖。

3. 规则配置工作量大，且易与预期不符

多表场景下要求用户为每张表的每个字段逐一配置造数规则，字段数随表数线性增长，配置工作量巨大；同时，用户对规则的理解可能与业务语义存在偏差，导致生成的数据"合规但不合理"，与实际预期不符。


二、方案设计与亮点

2.1 产品定位

基于 AI 大模型的智能测试数据生成平台：TestDataGen 是一个基于 AI 的智能测试数据生成工具，核心目标是解决传统测试数据生成工具存在的痛点，通过结合人工智能大模型能力和数据库元数据解析技术，自动生成符合业务规则和数据库约束的高质量测试数据。

2.2 整体工作流程

平台采用「五步向导」设计，用户从 SQL 粘贴到数据落库全程零编码：



2.3 核心设计思路

设计点	思路
AI + 规则双引擎	LLM 负责"语义合理"，规则引擎负责"约束合规"，两者互补而非取代
SQL 驱动一切	一条业务 SQL 即驱动表结构识别、关联关系发现、约束自动推导、生成顺序拓扑排序

设计点	思路
五级规则匹配	关联字段 → 用户规则 → 存储规则 → 启发式规则 → 默认生成器，最大化复用历史经验
快照可追溯	每个任务保留规则快照、分析快照、数据快照，问题可复现可审计
降级保底	大模型异常 → 内置规则；JSON 解析失败 → 兜底；超长 → 截断；多模型轮询切换

2.4 亮点一：简单高效的用户操作

传统测试数据工具往往需要用户逐字段配置生成规则，多表场景下配置工作量随字段数线性增长。本平台从三个层面系统性降低了用户操作成本：

层面一：SQL 约束自动推导 — "SQL 即规则"

用户只需粘贴一条业务 SQL，平台即自动从 `WHERE` 和 `JOIN ON` 条件中提取语义约束，反向转化为字段生成规则，无需手工配置：

```
-- 用户输入的 SQL
WHERE business_status IN ('ACTIVE', 'INACTIVE')
  AND establish_date >= '2020-01-01'
  AND establish_date <= '2024-12-31'
  AND age > 18
```

平台自动推导：

- `business_status` → 枚举规则 `['ACTIVE', 'INACTIVE']` (IN 列表提取)
- `establish_date` → 范围规则 `[2020-01-01, 2024-12-31]` (同列 `>=` 与 `<=` 自动合并取交集)
- `age` → 范围规则 `min=18` (比较运算符提取)

层面二：规则自动回填 + AI 一键推荐

进入规则配置页时，系统自动执行多层回填，用户大多数情况下只需确认即可：

回填优先级（由高到低）：

- ① 已保存规则 - 上次任务中用户手动确认过的规则
- ② WHERE 推导 - 从 SQL 约束自动推导（标记为"WHERE"来源，黄色标识）
- ③ 历史规则 - 其他任务中相同字段的规则（标记为"HISTORY"，蓝色标识）
- ④ 知识库匹配 - 企业知识库中的规则建议（标记为"KNOWLEDGE_BASE"，紫色标识）
- ⑤ 启发式识别 - 内置规则库自动匹配（如 email 列 → 邮箱正则）

若自动回填仍不满意，用户可一键触发"AI 建议规则"，由大模型分析整张表结构后批量输出每列建议，直接回填到配置表单。

层面三：预览即所得，一键写入

配置完成后点击"预览"即可看到生成效果，不满意可列级重新生成或单元格双击编辑，确认后一键写入数据库。全表事务原子提交，任意表失败自动回滚。

2.5 亮点二：多元化造数规则支持

四种核心策略：

策略	精确度	典型用途	实现引擎
AI 语义生成	语义级	姓名、地址、公司名、订单备注	大模型批量生成
正则表达式	格式级	身份证号、手机号、信用代码	RgxGen 正则反向生成
范围值	数值级	金额、年龄、日期区间	区间均匀随机
枚举值	离散级	状态码、性别、业务类型	加权随机抽样

五级规则匹配优先级：

- ① 关联字段列（最高优先） → ForeignKeyGenerator，自动从父表 PK 值池引用
- ② 用户规则 → 本次任务中用户明确指定的规则
- ③ 存储规则 → 数据库中保存的规则，支持通配符模式
- ④ 启发式规则 → 内置规则库自动识别（email → 邮箱正则，phone → 手机号等）
- ⑤ 默认生成器（兜底） → 基于数据类型（DataFaker）生成基础值

对 SQL 脚本进行拆解析，提取脚本中的关联字段、WHERE 条件等关键信息，通过代码实现关联字段的造数操作，确保关联字段造数成功率达到 100%。基于"人机结合"理念，对重要功能

进行拆分，确保重要字段造数成功率达 100%；对于其他造数功能，则交由 AI 处理并设置兜底逻辑，保障测试数据生成成功。

列级无损重新生成：预览后发现某列数据不满意时，无需重新生成整张表。用户选中目标列，修改规则后仅该列重新调用生成器，其他列数据完全保持不变。关联字段列自动从已有父表数据中提取引用值，保证引用完整性。

2.6 亮点三：高效可控利用大模型

核心理念：不是将库表结构和造数需求一股脑丢给大模型，而是通过 SQL 解析等预处理手段，将大模型调用收敛到“按字段维度”的精确调用，同时利用大模型的语义理解能力辅助规则推荐。

平台采用“预处理 + 按字段精确调用 + 规则引擎兜底”的分层架构：

第一层：SQL 解析预处理（SqlParserService）
• 解析表结构、字段类型、长度约束
• 提取 WHERE/ON 约束 → 自动推导为枚举/范围规则
• 识别表间关联关系 → 自动绑定 ForeignKeyGenerator
• 拓扑排序 → 确定多表生成顺序
第二层：规则引擎匹配（RuleMatchingEngine）
• 5 级优先级自动匹配：关联字段 → 用户规则 → 存储规则 → 启发式 → 默认生成器
• 正则/范围/枚举/序列等确定性策略由对应 Generator 处理
• 仅 LLM_DESCRIPTION 类型的字段才进入大模型调用流程
第三层：按字段维度精确调用大模型（LlmService）
• 每次调用只针对单个字段，Prompt 精确包含： 表名、列名、数据类型、长度约束、可空性、语义描述
• 单次请求返回 50 条值，存入线程安全值池；多个 LLM 字段并发调用
第四层：容错降级（全链路兜底）
• API 调用失败 → 重试 3 次（指数退避）
• 全部重试失败 → DefaultGenerator 按数据类型兜底生成
• 并发异常 → 回退串行模式；Markdown 响应 → 自动清理代码块标记

对比：

维度	整表丢给 AI	平台的"预处理+字段级调用"
单次 Prompt 信息量	全表 10+ 列结构 + 所有约束	单字段定义 + 精确约束
Token 消耗	高（输入+输出均大规模）	低（按字段拆分，每次仅单列）
约束遵守率	随列数增长而下降	单列约束简单，遵守率极高
出错影响面	整表需重新生成	仅影响单列，可列级重生成
确定性策略	无法与 AI 混合编排	正则/范围/枚举/AI 自由组合
FK 处理	模型难以保证引用完整性	引擎自动追踪 PK，FK 精确引用
容错能力	模型失败则整表无数据	LLM 失败回退默认生成器

AI 规则推荐：除了数据生成，平台还利用大模型做"规则推荐"——让 AI 做它擅长的事（理解语义、推荐策略），而不是让它做确定性程序更擅长的事（格式校验、范围约束、FK 引用）。

大模型幻觉问题的解决：

大模型在生成测试数据时普遍存在"幻觉"问题——输出看似合理但实际不符合业务约束的数据（如编造不存在的行政区划代码、生成格式错误的证件号、产出与字段语义无关的随机文本）。平台通过两个层面系统性抑制幻觉：

1. 知识库约束：用确定性知识替代模型猜测

对于有明确业务规范的字段（手机号、身份证、统一社会信用代码、行政区划、银行卡号、业务状态码等），平台优先从知识库中匹配已验证的生成规则，**完全绕过大模型调用**，从根本上消除幻觉可能：

- 知识库中每个条目均经过验证，包含精确的正则 pattern、枚举值列表或范围约束
- 字段名/注释命中知识库时直接使用确定性生成器（REGEX/ENUM/RANGE），不走 LLM
- 命中知识库的字段响应延迟从 ~1.7s 降至 < 50ms，同时幻觉率降为 0

2. 提示词按字段维度精准限制：缩小幻觉空间

对于必须调用大模型的语义类字段（姓名、地址、公司名、备注等），平台通过将 Prompt 收敛到**单字段维度**，最大限度压缩模型的"自由发挥空间"：

- **约束显式化：**每次 Prompt 仅包含单个字段的完整约束信息（数据类型、最大长度、可空

性、语义描述)，模型需要"遵守"的规则极少，遵从率极高

- **输出格式固定**：要求模型严格返回 JSON 数组，格式简单明确，不会在格式上产生幻觉
- **长度硬约束**：Prompt 中明确标注 `maxLength`，即使模型偶尔超长，后置截断兜底确保数据不会因幻觉溢出
- **上下文隔离**：不同字段的 Prompt 互相独立，避免模型因上下文过长而"记混"约束、产生字段间串扰

对比：整表级 Prompt 中模型需同时满足 10+ 列约束，注意力分散导致幻觉频发；字段级 Prompt 中模型仅需关注 1 个字段的 1 组约束，幻觉空间被压缩到最小。

三、成果展示

3.1 效率价值

指标	传统方式	本工具	提升
单表 1000 行造数耗时	~30 分钟（手写 SQL）	< 30 秒	60x
7 表关联宽表造数耗时	~半天到一天	< 2 分钟	60x~240x
字段规则配置时间	逐字段配置	60%+ 自动回填	3x~5x
调整单列数据	重新整表生成	列级重生	$O(N) \rightarrow O(1)$

3.2 质量价值

- **关联关系 100% 命中**：宽表 LEFT JOIN 无 NULL miss
- **约束合规率 >= 95%**：长度、正则、枚举、唯一约束全部满足
- **AI 综合得分 92.0 (S 级)**：deepseek-v4-pro 在字段值生成与规则建议两大场景实测
- **回退机制全通过**：网络异常、JSON 失败、长度超限、模型切换 4 项验证 100% 通过

3.3 AI 能力测评

对系统的两个核心 AI 能力（行级值生成、规则建议）建立了可复用的测评框架，并完成基线评测。

模型对比与综合评分

模型	场景 A（字段值生成）	场景 B（规则建议）	总分	等级
deepseek-v4-pro	94.6	85.9	92.0	S
mimo-v2.5-pro	82.5	75.4	80.3	A

回退机制验证结果

验证项	结果
网络异常自动降级到规则生成	通过
JSON 解析失败兜底	通过
超长数据截断兜底	通过
切换备用模型	通过

3.4 端到端验证（工商企业宽表）

专门构建了一个高复杂度的银行业"全量工商企业信息宽表"场景作为端到端验证基线：

场景复杂度：

- 7 张源表 + 1 张 80+ 字段宽表
- 9 个 LEFT JOIN + 5 个复合 ON 条件
- 5 类业务码值字典
- 3 个 UNIQUE 约束
- 多精度 DECIMAL（18,4 / 18,2 / 10,6 / 6,4）

验证结果：

设计功能	验证结果
多表依赖拓扑排序	严格按拓扑层级生成，无引用空值
关联关系严格满足	100% 关联命中，宽表关联无 NULL miss
关联字段长度对齐	所有关联字段长度严格一致，无截断错位

设计功能	验证结果
复合 JOIN 条件遵从	子表生成时自动满足复合过滤条件
码值字典约束	5 类业务码值全部命中字典，无脏值
唯一约束遵从	批量插入无重复冲突
WHERE 约束转生成约束	生成数据 100% 满足 WHERE 条件
多精度 DECIMAL	各精度均按定义生成，无溢出


结论：场景中所有 80+ 字段、9 个 JOIN、5 类码值映射、3 个唯一约束、10+ 处 COALESCE 融合，**全部按设计预期跑通**，证明系统从 SQL 解析到数据落库的全链路在工业级复杂度下依然成立。

该场景已固化为标准回归基线，每次涉及 SQL 解析、依赖编排、约束推导的改动都会以此场景作为最低验收门槛。

四、流程演示


Step 1 — 进入首页（执行历史）

- 登录工具，默认进入首页"执行历史"
- 列表展示所有已执行造数任务：状态、目标 SQL、关联表、行数、创建时间
- 支持刷新、筛选、查看详情
- 点击「**新建任务**」开始新一轮造数




Step 2 — 数据库连接配置

- 选择数据库类型（MySQL / PostgreSQL / Oracle / ...）
- 填写连接参数：连接名称、IP、端口、账号、密码、数据库名
- 点击「测试连接」→ 提示"连接成功"
- 点击「保存」留存常用连接，下次直接选用
- 点击「下一步」进入 SQL 解析




Step 3 — SQL 导入与解析


- 在编辑区输入业务 SQL（INSERT-SELECT 多表加工脚本）
- 支持本地 SQL 文件导入 / 常用脚本保存调用
- 点击「解析 SQL」



- 工具自动识别：
 - 目标表与字段（含类型、注释、长度、PK/AI/NN）
 - 表间关联关系
 - 生成拓扑顺序
 - WHERE/ON 约束



- 解析结果以字段详情表展示：字段名、类型、属性、注释、关联引用一目了然



Step 4 — 字段规则配置

- 系统自动加载所有字段，**自动回填默认规则**（5级优先级）
- 自动跳过：自增列、关联引用列（引擎自动处理）

字段名	类型	注释	规则类型	规则配置	来源	历史
ent_id	varchar(36)	企业ID	关联关系	+ t_merchant_base.ent_id		
unified_code	varchar(32)	统一社会信用代码	AI 生成	统一社会信用代码	历史	重
ent_name	varchar(256)	企业全称	AI 生成	企业全称	历史	重
ent_short_name	varchar(128)	企业简称	AI 生成	企业简称	历史	重
ent_type_code	varchar(32)	企业类型编码(对齐t_upstream_code.code_key)	关联关系	+ t_upstream_code.code_key		
ent_type_name	varchar(64)	企业类型名称	AI 生成	企业类型名称	历史	重
reg_type_code	varchar(32)	注册类型编码(对齐t_upstream_code.code_key)	关联关系	+ t_upstream_code.code_key		
reg_type_name	varchar(64)	注册类型名称	AI 生成	注册类型名称	历史	重
reg_capital	decimal(18,4)	注册资本(万元)	范围	0 ~ 最大值 整数	WHERE	重
paid_capital	decimal(18,4)	实缴资本(万元)	AI 生成	实缴资本(万元)	历史	重
currency_code	varchar(8)	币种	AI 生成	币种	历史	重
establish_date	date	成立日期	范围	1900-01 ~ 最大值 日期	WHERE	重
business_status	varchar(16)	经营状态: 1存续 2在业 3吊销 4注销 5迁出	枚举	1,2	WHERE	重
reg_address	varchar(512)	注册地址	AI 生成	注册地址	历史	重
business_address	varchar(512)	经营地址	AI 生成	经营地址	历史	重
province_code	varchar(128)	省份编码(对齐t_gs_key.key_value)	关联关系	+ t_gs_key.key_value		
province_name	varchar(64)	省份名称	AI 生成	省份名称	历史	重
city_code	varchar(128)	城市编码(对齐t_gs_key.key_value)	关联关系	+ t_gs_key.key_value		
city_name	varchar(64)	城市名称	AI 生成	城市名称	历史	重

- 对剩余字段，选择规则类型并配置：
 - AI 语义生成 (LLM_DESCRIPTION)**：姓名、地址、公司名、订单备注等
 - 正则表达式 (REGEX)**：身份证、手机号、统一社会信用代码等
 - 枚举值 (ENUM)**：状态码、性别、省份、业务类型等
 - 范围值 (RANGE)**：金额、年龄、数量、日期区间等

t_merchant_base

数据规则

AI 建议规则

字段名	类型	注释	规则类型	规则配置	来源	历史
merchant_id	varchar(32)	商户ID	正则	[a-zA-Z0-9]{32}	A1	
ent_id	varchar(36)	企业ID(关联t_enterprise_base)	正则	[a-f0-9]{8}-[a-f0-9]{4}-[a-f0-9]{4}-[a-f0-9]{4}-[a-f0-9]	A1	
cust_no	varchar(32)	客户号(关联t_customer_identity)	关联关系	= t_customer_identity.cust_no		
merchant_name	varchar(256)	商户名称	AI 生成	生成一个合理的中文商户名称, 例如“北京宏图科技有限公司”或“上海明珠餐	A1	
merchant_short	varchar(128)	商户简称	AI 生成	生成商户的简称或品牌缩写, 例如“宏图科技”或“明珠餐饮”, 长度不超过128	A1	
merchant_type	varchar(16)	商户类型: 1实体店 2电商 3连锁 4个体工商户	枚举	1,2,3,4	A1	
biz_category	varchar(32)	经营类目编码	关联关系	= t_external_code.code_item		
biz_category_name	varchar(128)	经营类目名称	AI 生成	生成与经营类目编码对应的中文类目名称, 如“餐饮服务”、“信息技术”、“配	A1	
settle_account	varchar(32)	结算账户	正则	[0-9]{16,19}	A1	
settle_bank	varchar(128)	开户行	AI 生成	生成国内常见银行名称, 例如“中国工商银行”、“中国建设银行”、“招商银行”	A1	
settle_bank_code	varchar(16)	开户行行号	正则	[0-9]{12}	A1	
settle_cycle	varchar(8)	结算周期: 10/11/17/130	枚举	T0,T1,T7,T30	A1	
settle_rate	decimal(6,4)	结算费率	范围	最小值 = 1 小数	A1	
merchant_status	char(1)	商户状态: 1正常 2待审核 3暂停 4注销	枚举	1,2,3,4	A1	
sign_date	date	签约日期	范围	2020-01 - 2023-12 日期	A1	
expiry_date	date	到期日期	范围	2024-01 - 2030-12 日期	A1	
contact_name	varchar(128)	联系人	AI 生成	生成一个常见的中文姓名, 长度不超过128个字符。	A1	
contact_phone	varchar(32)	联系电话	正则	1{3-9}[0-9]{9}	A1	
contact_email	varchar(128)	联系邮箱	正则	[a-zA-Z0-9_%.%+]*@[a-zA-Z0-9_%.%+]*\.[a-zA-Z]{2,}	A1	
contact_address	varchar(512)	联系地址	AI 生成	生成一个详细的中文地址, 包含省市区街道等信息, 例如“北京市朝阳区建国	A1	
risk_level	char(1)	风险等级: 1低 2中 3高	枚举	1,2,3	A1	
credit_score	int	信用评分(0-1000)	范围	最小值 = 1000	A1	

TestDataGen

测试数据构造工具

数据规则

AI 建议规则


上一步

下一步: 数据生成

- 辅助功能：
 - 一键 AI 建议：整表字段批量推荐
 - 字段历史规则：查看/复用历史使用记录

Step 5 — 数据生成

- 选择内置 AI 生成模型（deepseek-v4-pro / mimo-v2.5-pro）
- 填写本次生成行数
- 点击「生成数据」
- 系统按规则并行批量构造：
 - 表间并行（同层无依赖表）
 - 字段级并发（每字段独立异步）
 - 50 条/批 LLM 批量调用




Step 6 — 数据预览与校验

- 预览表格展示完整数据
- 支持：
 - 单条数据手动修改
 - **单列数据重新生成**（列级无损刷新）
 - 字段格式 / 业务逻辑 / 数据范围核对
- 不满意 → 调整规则后重生该列，其他列保持不变

t_full_enterprise_info								重新生成选中列 (0)	对比	10 行
#	☐ RECORD_ID	☒ CUST_NO	☐ ENT_ID	☐ MERCHANT_ID	☐ UNIFIED_CODE	☐ CREDIT_CODE_STATUS	☐ ENT_NAME			
1	a1b2c3d4e5f6789012345678abcdef01	CUST20250115001		34051823	91350100MA345JXW5R	正常	深圳市腾讯计算机系统有限公司			
2	1a2b3c4d5e6f7890abcdef1234567890	8849930212345678	2024120501	7392104856310274	91110108MA01CKJ67N	吊销	阿里巴巴（中国）网络技术有限			
3	17000000000001234567	CN-2025-A783C9	9876543210	6150483920174568	91440300MA50CY739U	注销	北京字节跳动科技有限公司			
4	REC20240315000001	f47ac10b58cc4372a5670e02b2c3d479	1122334455	9201748365029183	510624211123456	停业	华为技术有限公司			
5	ENT_2024_03_15_000001	SNOW-20250115-001	3098765432	3472891056348209	320582199001011234	在业	中国平安保险（集团）股份有限			
6	ABCDEFGHIJKLMN0PQRSTUUVWXYZ1234	2025011512345678	5566778899	1857304920683514	91131024MA07XEQY2T	迁出	京东集团股份有限公司			
7	20240315123456001	ENT1000000001	7712345678	5061284739012567	91350200MA348UXL1D	异常	百度在线网络技术（北京）有限			
8	recordid1234567890abcdefg hij	A182C304E5F667H8	8901234567	8349056127983402	44030519881012001X	存续	小米科技有限责任公司			

Step 7 — 数据入库与执行历史归档

- 校验通过 → 点击「写入数据库」
- 系统事务化批量写入目标表
- 执行完成后自动返回执行结果：
 - 关联库表结构（ER 关系图）
 - 完整 SQL 语句
 - 造数规则快照
 - 数据写入结果 / 错误日志
- 任务自动归档至首页执行历史，保存三类快照（规则、分析、数据）
- 下次相同场景可一键基于历史任务复用



演示地址

访问地址 <http://8.130.81.216/>

详细技术方案与架构细节参见 [PRODUCT_INTRO.md](#)；完整界面操作步骤参见 [智能测试数据生成工具操作手册.pdf](#)。