



智能测试数据生成工具 · 演示文档

一份面向产品宣讲、客户演示与团队对齐的综合材料，配合
智能测试数据生成工具操作手册.pdf 使用。

目录


- 一、方案设计
- 二、痛点
- 三、亮点
- 四、成果价值
- 五、流程演示

一、方案设计

1.1 产品定位

基于 AI 大模型的智能测试数据生成平台：通过解析业务 SQL，自动理解数据库表结构与表间关联关系，将 AI 大模型的语义生成能力与规则引擎的精确约束能力深度融合，**一键生成既符合业务语义又满足所有数据库约束的真实感测试数据**，并以事务方式直接写入目标数据库，同时完整记录任务执行快照供追溯复现。

1.2 总体架构



1.3 核心设计思路

设计点	思路
AI + 规则双引擎	LLM 负责"语义合理", 规则引擎负责"约束合规", 两者互补而非取代
SQL 驱动一切	一条业务 SQL 即驱动表结构识别、关联关系发现、约束自动推导、生成顺序拓扑排序
五级规则匹配	关联字段 → 用户规则 → 存储规则 → 启发式规则 → 默认生成器, 最大化复用历史经验
快照可追溯	每个任务保留规则快照、分析快照、数据快照, 问题可复现可审计

设计点	思路
降级保底	大模型异常 → 内置规则；JSON 解析失败 → 兜底；超长 → 截断；多模型轮询切换

1.4 关键技术

- **SQL 解析**：JSqlParser + 自研 ON/WHERE 约束抽取
- **AI 调用**：OpenAI 兼容协议，支持 deepseek-v4-pro / mimo-v2.5-pro 双模型，支持 Extended Thinking
- **生成引擎**：DataFaker + 自研正则反向求解 + LLM 批量调用
- **并发优化**：表间 `CompletableFuture.allOf` 并行 + 字段级专用线程池 + 50 条/批 LLM 调用
- **可视化**：纯 HTML5 Canvas 绘制 ER 关系图（无外部图形库依赖）

二、痛点

2.1 传统造数方式的核心痛点

痛点	具体表现
效率低下	手写 INSERT、写脚本、调用 mock 工具，多表场景动辄半天起步
真实感差	mock 工具产出的"张三-15812345678-test@mail.com"一眼假，业务测试无说服力
关联关系易错	多表 JOIN 场景下，子表外键值经常对不上父表，导致 LEFT JOIN 全是空
约束难满足	字段长度、正则、枚举、范围、唯一约束等需逐一手工保证，遗漏即批量失败
不可复现	哪天造的数？用什么规则？为什么这次和上次不一样？无任何记录
重复劳动	同一字段每个人都要重新踩坑，配过的优质规则没人沉淀，下次冷启动
跨表语义错位	即使单字段合规，行内字段间也常矛盾（如 birthday 与 age 不一致、name 与 gender 错位）

2.2 复杂业务场景下的特定痛点

以银行业典型的"全量工商企业宽表"为例：

- 7 张源表 → 1 张 80+ 字段宽表：手工造数几乎不可行
- 9 个 LEFT JOIN + 5 个复合 ON 条件：稍有不慎就是 NULL miss
- 5 类业务码值字典：手工对齐编码 ↔ 名称极易错
- 3 个 UNIQUE 约束：批量插入冲突频发
- 多精度 DECIMAL (18,4 / 18,2 / 10,6 / 6,4) ：精度溢出问题屡见不鲜

2.3 现有 AI 造数工具的痛点

类型	局限
通用 LLM 直答	不懂表结构、不懂约束，给出的数据无法直接入库
纯规则工具	真实感差、无法理解字段语义
各方言脚本工具	学习成本高、无可视化、不支持复杂关联

三、亮点

3.1 SQL 一键解析，自动推导一切

输入一条业务 SQL，工具自动产出：

- 表清单与字段元数据（类型、长度、注释、PK/AI/NN、关联关系）
- 表间关联关系图（可视化 ER 图，可拖拽，按层着色）
- 数据生成拓扑顺序（父表先于子表）
- WHERE/ON 约束 → 生成规则（如 `status IN ('1','2')` 自动转 ENUM）

3.2 智能规则回填（5 级优先级）

打开规则配置页，60%+ 字段已自动配置完成，用户仅需关注剩余字段：

优先级	来源	颜色标记
1	WHERE/ON 条件自动推导	● 黄色
2	历史规则复用（同库同表同列）	● 蓝色
3	知识库匹配（手机号/身份证等标准字段）	● 紫色
4	字段注释语义识别	○ 灰色
5	启发式内置规则（邮箱、状态、性别等）	—

3.3 一键 AI 建议规则

针对整张表，调用大模型基于（字段名+类型+注释+关联关系）一次性给出整表所有字段的最优规则建议，实测 **deepseek-v4-pro 综合评分 92.0 (S 级)**。

3.4 关联关系强一致

- 关联字段值池由父表生成结果实时供应，**100% 命中**
- 关联字段长度严格对齐（VARCHAR(128) ↔ VARCHAR(128)，永不截断）
- 复合 ON 条件穿透到子表生成规则（如 `cert_status='1'` 自动应用到证件表生成）
- 同名同义字段长度对齐：父子表跨表关联字段长度自动校验对齐

3.5 列级无损重新生成

预览数据后某列不满意？

- 仅该列重新调用生成器
- 其他列数据完全保持不变
- 关联字段列自动从已有父表数据中提取引用值
- 调整效率从 O(全表) → O(单列)

3.6 完整快照可追溯

每次任务自动保存三类快照：

快照类型	内容	用途
规则快照	本次使用的所有字段规则	复用 / 复盘
分析快照	SQL 解析的表结构、关联、拓扑	排查问题
数据快照	实际写入的所有数据	回溯审计

3.7 多模型容错与降级

- 双模型轮询：deepseek-v4-pro（默认 S 级）+ mimo-v2.5-pro（备份 A 级）
- 网络异常 → 自动降级到内置规则生成
- JSON 解析失败 → 解析兜底
- 长度超限 → 截断兜底而非整批丢弃

3.8 可视化端到端引导

- Stepper 6 步引导，每步都有明确入口和校验
- 数据预览支持单条修改、单列重生
- ER 关系图可拖拽，长依赖链自动分层
- 任务执行历史一键查看

四、成果价值

4.1 效率价值

指标	传统方式	本工具	提升
单表 1000 行造数耗时	~30 分钟（手写 SQL）	< 30 秒	60×
7 表关联宽表造数耗时	~半天到一天	< 2 分钟	60×~240×
字段规则配置时间	逐字段配置	60%+ 自动回填	3×~5×
调整单列数据	重新整表生成	列级重生	O(N) → O(1)

4.2 质量价值

- **关联关系 100% 命中**：宽表 LEFT JOIN 无 NULL miss
- **约束合规率 ≥ 95%**：长度、正则、枚举、唯一约束全部满足
- **AI 综合得分 92.0 (S 级)**：deepseek-v4-pro 在字段值生成与规则建议两大场景实测
- **回退机制全通过**：网络异常、JSON 失败、长度超限、模型切换 4 项验证 100% 通过

4.3 业务价值

角色	收益
测试工程师	从"造数搬砖工"转向"用例设计师", 把时间花在测试逻辑而非造数本身
业务分析师	高真实感数据让业务测试场景具备说服力, 需求评审更顺畅
DBA / 架构师	SQL 驱动的解析 + 完整快照, 数据来源可审计可追溯
管理层	测试数据准备从瓶颈环节变成可量化、可复用的产线能力

4.4 端到端验证（工商企业宽表）

在一个银行业真实复杂度的"全量工商企业信息宽表"场景中：

- 7 张源表 + 1 张 80+ 字段宽表 全部跑通
- 9 个 LEFT JOIN 全部命中，**无任何 NULL miss**
- 5 类码值字典严格遵从，**无脏值**
- 3 个 UNIQUE 约束批量插入**无冲突**
- 多精度 DECIMAL、TEXT 大字段、复合 ON 条件 **全部按设计跑通**


该场景已固化为标准回归基线，每次涉及 SQL 解析、依赖编排、约束推导的改动都以此为最低验收门槛。

五、流程演示

完整 7 步流程，每步附操作截图。

Step 1 — 进入首页（执行历史）


- 登录工具，默认进入首页"执行历史"
- 列表展示所有已执行造数任务：状态、目标 SQL、关联表、行数、创建时间
- 支持刷新、筛选、查看详情
- 点击「新建任务」开始新一轮造数



💡 演示要点：强调"以历史为中心"的导航理念，老任务可一键复用规则。

Step 2 — 数据库连接配置


- 选择数据库类型（MySQL / PostgreSQL / Oracle / ...）
- 填写连接参数：连接名称、IP、端口、账号、密码、数据库名
- 点击「测试连接」→ 提示"连接成功"
- 点击「保存」留存常用连接，下次直接选用
- 点击「下一步」进入 SQL 解析



💡 演示要点：连接信息加密保存，支持复用，避免重复填写。


Step 3 — SQL 导入与解析

- 在编辑区输入业务 SQL (INSERT-SELECT 多表加工脚本)
- 支持本地 SQL 文件导入 / 常用脚本保存调用
- 点击「解析 SQL」




- 工具自动识别：
 - 目标表与字段（含类型、注释、长度、PK/AI/NN）
 - 表间关联关系

- 生成拓扑顺序
- WHERE/ON 约束



- 解析结果以 **字段详情表** 展示：字段名、类型、属性、注释、关联引用一目了然



- 确认无误 → 「**下一步：规则配置**」

💡 演示要点：拿一条 7 表 9 JOIN 的复杂 SQL 当场解析，2 秒内出图，最直观。

Step 4 — 字段规则配置

- 系统自动加载所有字段，**自动回填默认规则**（5 级优先级）：
 - WHERE 条件推导
 - 历史规则复用
 - 知识库匹配
 - 字段注释识别
 - 启发式内置规则
- 自动跳过：自增列、关联引用列（引擎自动处理）

字段名	类型	注释	规则类型	规则配置	来源	历史
ent_id	varchar(36)	企业ID	关联关系	+ t_merchant_base.ent_id		
unified_code	varchar(32)	统一社会信用代码	AI 生成	统一社会信用代码	历史	重
ent_name	varchar(256)	企业全称	AI 生成	企业全称	历史	重
ent_short_name	varchar(128)	企业简称	AI 生成	企业简称	历史	重
ent_type_code	varchar(32)	企业类型编码(对齐t_upstream_code.code_key)	关联关系	+ t_upstream_code.code_key		
ent_type_name	varchar(64)	企业类型名称	AI 生成	企业类型名称	历史	重
reg_type_code	varchar(32)	注册类型编码(对齐t_upstream_code.code_key)	关联关系	+ t_upstream_code.code_key		
reg_type_name	varchar(64)	注册类型名称	AI 生成	注册类型名称	历史	重
reg_capital	decimal(18,4)	注册资本(万元)	范围	0 ~ 最大值 整数	WHERE	重
paid_capital	decimal(18,4)	实缴资本(万元)	AI 生成	实缴资本(万元)	历史	重
currency_code	varchar(8)	币种	AI 生成	币种	历史	重
establish_date	date	成立日期	范围	1900-01 ~ 最大值 日期	WHERE	重
business_status	varchar(16)	经营状态: 1存续 2在业 3吊销 4注销 5迁出	枚举	1,2	WHERE	重
reg_address	varchar(512)	注册地址	AI 生成	注册地址	历史	重
business_address	varchar(512)	经营地址	AI 生成	经营地址	历史	重
province_code	varchar(128)	省份编码(对齐t_gs_key.key_value)	关联关系	+ t_gs_key.key_value		
province_name	varchar(64)	省份名称	AI 生成	省份名称	历史	重
city_code	varchar(128)	城市编码(对齐t_gs_key.key_value)	关联关系	+ t_gs_key.key_value		
city_name	varchar(64)	城市名称	AI 生成	城市名称	历史	重

- 对剩余字段，选择规则类型并配置：
 - AI 语义生成 (LLM_DESCRIPTION)**：姓名、地址、公司名、订单备注等
 - 正则表达式 (REGEX)**：身份证、手机号、统一社会信用代码等
 - 枚举值 (ENUM)**：状态码、性别、省份、业务类型等
 - 范围值 (RANGE)**：金额、年龄、数量、日期区间等

t_merchant_base

数据模型图AI 建议规则

字段名	类型	注释	规则类型	规则配置	来源	历史
merchant_id	varchar(32)	商户ID	正则	[a-zA-Z0-9]{32}	A1	
ent_id	varchar(36)	企业ID(关联t_enterprise_base)	正则	[a-f0-9]{8}-[a-f0-9]{4}-[a-f0-9]{4}-[a-f0-9]{4}-[a-f0-9]	A1	
cust_no	varchar(32)	客户号(关联t_customer_identity)	关联关系	= t_customer_identity.cust_no		
merchant_name	varchar(256)	商户名称	AI 生成	生成一个合理的中文商户名称, 例如“北京宏图科技有限公司”或“上海明珠餐	A1	
merchant_short	varchar(128)	商户简称	AI 生成	生成商户的简称或品牌缩写, 例如“宏图科技”或“明珠餐饮”, 长度不超过128	A1	
merchant_type	varchar(16)	商户类型: 1实体店 2电商 3连锁 4个体工商户	枚举	1,2,3,4	A1	
biz_category	varchar(32)	经营类目编码	关联关系	= t_external_code.code_item		
biz_category_name	varchar(128)	经营类目名称	AI 生成	生成与经营类目编码对应的中文类目名称, 如“餐饮服务”、“信息技术”、“配	A1	
settle_account	varchar(32)	结算账户	正则	[0-9]{16,19}	A1	
settle_bank	varchar(128)	开户行	AI 生成	生成国内常见银行名称, 例如“中国工商银行”、“中国建设银行”、“招商银行”	A1	
settle_bank_code	varchar(16)	开户行行号	正则	[0-9]{12}	A1	
settle_cycle	varchar(8)	结算周期: 10/11/17/130	枚举	T0,T1,T7,T30	A1	
settle_rate	decimal(6,4)	结算费率	范围	最小值 = 1 小数	A1	
merchant_status	char(1)	商户状态: 1正常 2待审核 3暂停 4注销	枚举	1,2,3,4	A1	
sign_date	date	签约日期	范围	2020-01 - 2023-12 日期	A1	
expiry_date	date	到期日期	范围	2024-01 - 2030-12 日期	A1	
contact_name	varchar(128)	联系人	AI 生成	生成一个常见的中文姓名, 长度不超过128个字符。	A1	
contact_phone	varchar(32)	联系电话	正则	1[3-9][0-9]{9}	A1	
contact_email	varchar(128)	联系邮箱	正则	[a-zA-Z0-9_%.%+]*@[a-zA-Z0-9_%.%+]*\.[a-zA-Z]{2,}	A1	
contact_address	varchar(512)	联系地址	AI 生成	生成一个详细的中文地址, 包含省市区街道等信息, 例如“北京市朝阳区建国	A1	
risk_level	char(1)	风险等级: 1低 2中 3高	枚举	1,2,3	A1	
credit_score	int	信用评分(0-1000)	范围	最小值 = 1000	A1	

TestDataGen 测试数据构造工具

数据模型图

业务域	字段名	类型	注释	规则类型	规则配置	来源	历史
business_scope	industry_code	varchar(32)	行业分类编码(对应t_external_code.code_item)	关联关系	= t_external_code.code_item		
	industry_name	varchar(128)	行业分类名称	AI 生成	行业分类名称		
reg_org	reg_org	varchar(128)	登记机关	AI 生成	登记机关		
	approval_date	date	核准日期	AI 生成	核准日期		
biz_term	biz_term_from	date	营业时间起始	AI 生成	营业时间起始		
	biz_term_to	date	营业时间截止	AI 生成	营业时间截止		
staff_count	staff_count	int	员工人数	AI 生成	员工人数		
	annual_revenue	decimal(18,2)	年营业收入(万元)	AI 生成	年营业收入(万元)		
tax_no	tax_no	varchar(32)	纳税人识别号	AI 生成	纳税人识别号		
	tax_type	varchar(16)	纳税人类型: 1一般纳税人 2小规模纳税人	AI 生成	纳税人类型: 1一般纳税人 2小规模纳税人		
ent_scale	ent_scale	varchar(32)	企业规模(对应t_upstream_code.code_key): 1大型...	关联关系	= t_upstream_code.code_key		
	hi_tech_flag	char(1)	高新技术企业标志: 1是 0否	AI 生成	高新技术企业标志: 1是 0否		
is_right_flag	is_right_flag	char(1)	进出口权标志: 1有 0无	AI 生成	进出口权标志: 1有 0无		
	listed_flag	char(1)	是否上市: 1是 0否	AI 生成	是否上市: 1是 0否		
listed_code	listed_code	varchar(16)	上市代码	AI 生成	上市代码		
	website	varchar(256)	企业网站	AI 生成	企业网站		
stockholder_info	stockholder_info	varchar(1024)	主要股东信息	AI 生成	主要股东信息		
	data_source	varchar(32)	数据来源	AI 生成	数据来源		
data_version	data_version	varchar(16)	数据版本	AI 生成	数据版本		
	create_time	timestamp	创建时间	AI 生成	创建时间		
update_time	update_time	timestamp	更新时间	AI 生成	更新时间		

上一步


下一步: 数据生成

- 辅助功能：
 - 一键 AI 建议：整表字段批量推荐
 - 字段历史规则：查看/复用历史使用记录
 - 空规则校验：禁止带空配置进入下一步

💡 演示要点：演示“一键 AI 建议”对整表 80+ 字段批量生成规则，30 秒搞定原本要 1 小时的工作。

Step 5 — 数据生成

- 选择内置 AI 生成模型（deepseek-v4-pro / mimo-v2.5-pro）
- 填写本次生成行数
- 再次核对目标表、SQL、关联表信息
- 点击「生成数据」
- 系统按规则**并行批量构造**：
 - 表间并行（同层无依赖表）
 - 字段级并发（每字段独立异步）
 - 50 条/批 LLM 批量调用



💡 演示要点：演示 7 表 1000 行 < 2 分钟跑完，进度实时刷新。

Step 6 — 数据预览与校验

- 预览表格展示完整数据
- 支持：
 - 单条数据手动修改
 - **单列数据重新生成**（列级无损刷新）

- 字段格式 / 业务逻辑 / 数据范围核对
- 排查脏数据、异常数据
- 不满意 → 调整规则后重生该列，其他列保持不变


The screenshot shows a data table titled 't_full_enterprise_info'. The table has columns: #, RECORD_ID, CUST_NO, ENT_ID, MERCHANT_ID, UNIFIED_CODE, CREDIT_CODE_STATUS, and ENT_NAME. A context menu is open over the 'CUST_NO' column, showing options: '重新生成此列' (Regenerate this column) and '修改规则后重新生成' (Regenerate after modifying rules). The table contains 8 rows of data, including records for companies like 深圳市腾讯计算机系统有限公司, 阿里巴巴(中国)网络技术有限公司, 北京字节跳动科技有限公司, 华为技术有限公司, 中国平安保险(集团)股份有限公司, 京东集团股份有限公司, 百度在线网络技术(北京)有限公司, and 小米科技有限责任公司.

#	RECORD_ID	CUST_NO	ENT_ID	MERCHANT_ID	UNIFIED_CODE	CREDIT_CODE_STATUS	ENT_NAME
1	a1b2c3d4e5f6789012345678abcdef01	CUST20250115001		34051823	91350100MA345JXWSR	正常	深圳市腾讯计算机系统有限公司
2	1a2b3c4d5e6f7890abcdef1234567890	8849930212345678	ZU2412U501	73V2104856310274	91110108MA01CKJ67N	吊销	阿里巴巴(中国)网络技术有限公司
3	1700000000001234567	CN-2025-A7B3C9	9876543210	6150483920174568	91440300MA50CY739U	注销	北京字节跳动科技有限公司
4	REC20240315000001	f47ac10b58cc4372a5670e02b2c3d479	1122334455	9201748365029183	510624211123456	停业	华为技术有限公司
5	ENT_2024_03_15_000001	SNOW-20250115-001	3098765432	3472891056348209	320582199001011234	在业	中国平安保险(集团)股份有限公司
6	ABCDEF6H1J2KLMNOPQRSTUVWXYZ1234	2025011512345678	5566778899	1857304920683514	91131024MA07XEQY2T	迁出	京东集团股份有限公司
7	20240315123456001	ENT1000000001	7712345678	5061284739012567	91350200MA348UXL1D	异常	百度在线网络技术(北京)有限公司
8	recordid1234567890abcdefghij	A182C3D4E5F667H8	8901234567	8349056127983402	44030519881012001X	存续	小米科技有限责任公司

💡 演示要点：演示"列级重生"——发现某列效果不好，30 秒重生该列，对比效果。

Step 7 — 数据入库与执行历史归档

- 校验通过 → 点击「写入数据库」
- 系统**事务化批量写入**目标表
- 等待执行完成 → 自动返回执行结果：
 - 关联库表结构
 - 完整 SQL 语句
 - 造数规则
 - 数据写入结果（成功）/ 错误日志（失败）
- 任务自动归档至首页执行历史，**保存三类快照**（规则、分析、数据）
- 下次相同场景可一键基于历史任务复用



💡 演示要点：成功后立即回到首页，展示新任务在历史列表里的快照三件套，强调可复现可追溯。

附：演示话术骨架（5 分钟版）

时间	重点	关键句
0:00–0:30	痛点引入	"你们的测试同学还在手写造数 SQL 吗？"
0:30–1:30	一句话方案	"一条业务 SQL 进，符合所有约束的真实数据出。"
1:30–3:30	核心流程演示	现场跑工商宽表 7 表 9 JOIN 场景
3:30–4:30	三大亮点强调	双引擎、关联强一致、列级重生
4:30–5:00	价值收口	"造数从半天到 2 分钟，约束合规率 95%+，质量验证 S 级。"

详细技术方案与架构细节参见 `PRODUCT_INTRO.md` ； 完整界面操作步骤参见
智能测试数据生成工具操作手册.pdf 。